网络爬虫实验

唐晶磊

信息工程学院

2023.11.11

1.实验目的

（1）理解网络爬虫相关概念及执行流程；
（2）熟练使用 requests 库、bs4 库中的常用方法；
（3）掌握独立编写爬虫程序并获取所需信息的能力。

2.实验平台

（1）操作系统：Windows 10；
（2）Python 版本：3.8.7；
（3）PyCharm 版本：PyCharm Community Edition 2020.2.1；

3.实验步骤

（一）显示影片基本信息

访问豆瓣电影 Top250（https://movie.douban.com/top250?start=0），获取每部电影的中文片名、排名、评分及其对应的链接，按照“排名-中文片名-评分-链接”的格式显示在屏幕上。

说明：

本实验中使用 CSS 选择器来获取标签，在此演示如何直接在浏览器获取指定元素的 CSS 选择器。

(1) 打开豆瓣电影 Top250 网页 https://movie.douban.com/top250?start=0

(2) 在网页上右击我们所要获取的信息；

例如：要获取《肖申克的救赎》电影的导演，将鼠标移至该电影的导演处，右击鼠标出现。

(3) 点击检查，即可定位该信息在 html 网页源码的具体位置；

(4) 右击对应标签，选择 Copy -> Copy selector,即可获得对应元素的 CSS 选择器。

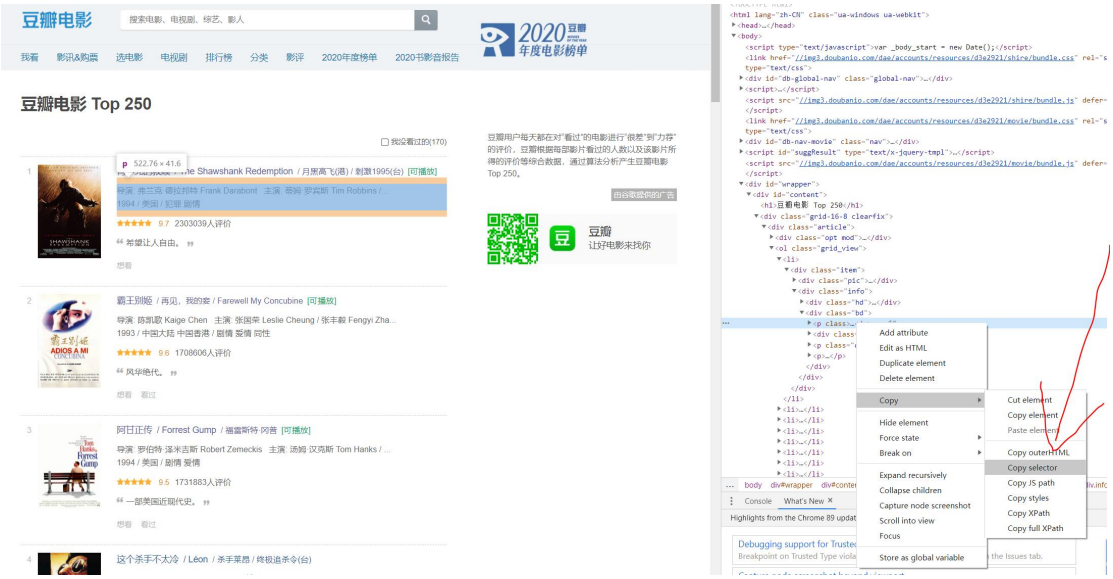

(5) 将复制得到的 CSS 选择器粘贴在 soup.select()中即可。

参考步骤：

(1) 在 PyCharm 中新建工程包，命名为 webCrawler；

(2) 在 webCrawler 工程下新建 doubanCrawler 文件夹；

(3) 在 doubanCrawler 文件夹下创建 getTop250.py 文件；

（二）存储影片详细信息

访问豆瓣电影 Top250（https://movie.douban.com/top250?start=0），在问题 1 的基础上，获取每部电影的（导演、编剧、主演、类型、上映时间）、片长、评分人数以及剧情简介等信息，并将获取到的信息保存至本地文件中。

说明：

本实验与第一个实验类似，但又有不同，需要处理子网页。第一个实验采用 CSS 选择器获取标签，本实验通过观察网页源码发现，主页电影信息全在 … 标签内，而且不同信息的 class 不同；子网页电影详细信息全在 … 中。所以为了简化代码，本实验使用 find()和 find_all()获取相应的标签。

由于实验将爬取到的数据保存至本地的 Word 文档中，所以需要下载并导入新的包 docx

参考步骤及过程：

在实验 1 创建的工程包 webCrawler 下的 doubanCrawler 文件夹下创建 downloadTop250.py；

（三）访问热搜榜并发送邮件

访问微博热搜榜（https://s.weibo.com/top/summary），获取微博热搜榜前 50 条热搜名称、链接及其实时热度，并将获取到的数据通过邮件的形式，每 20 秒发送到个人邮箱中。

注意事项：

1、定义请求头

本实验需要获取 User-Agent、Accept、Accept-Language、Accept-Ecoding、Cookie 五个字段，前四个字段可能都是相同的，主要是 Cookie 不同。具体获取流程如下：

①、打开目标网页，本实验目标网页为 https://s.weibo.com/top/summary

②、按键盘上面 F12 进入开发者模式，此时页面如下：

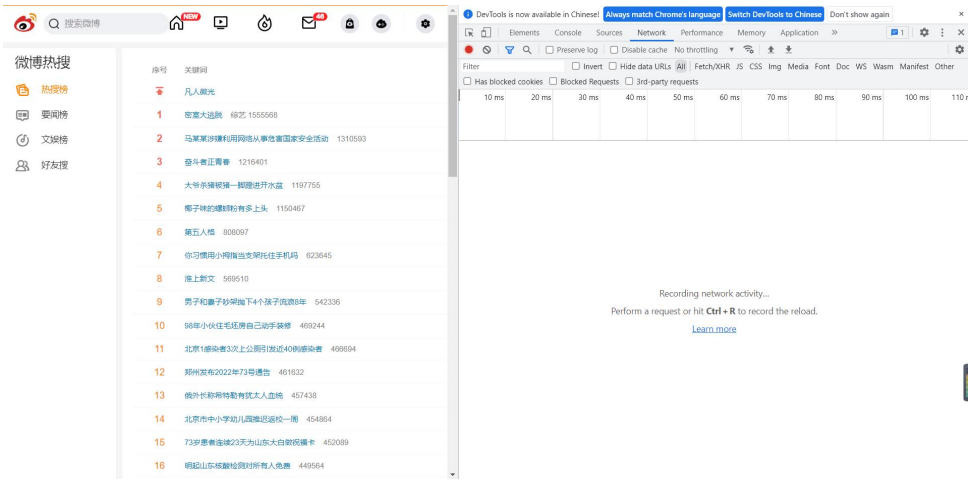

③、按键盘上面 F5 刷新页面，此时开发者模式中会有网页相关信息，页面如下：

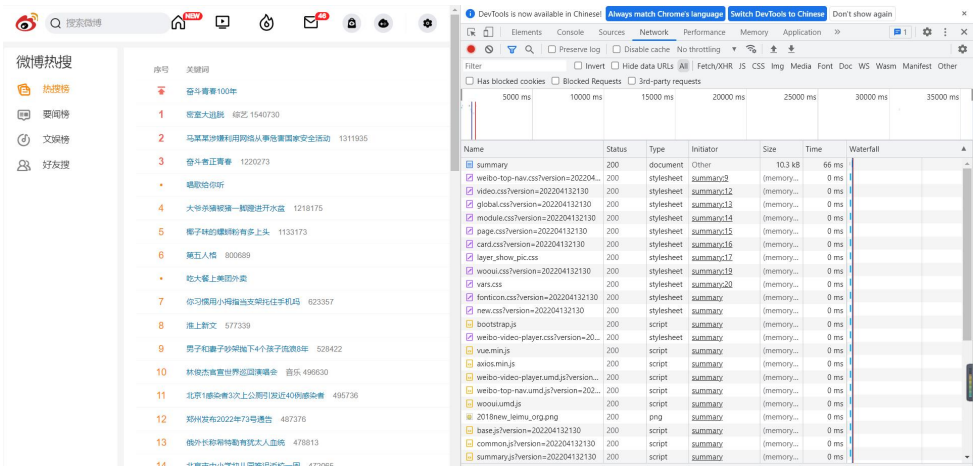

④、依次点击 Network、All、以及 summary（即目标链接的地址），各个位置如下图所示：

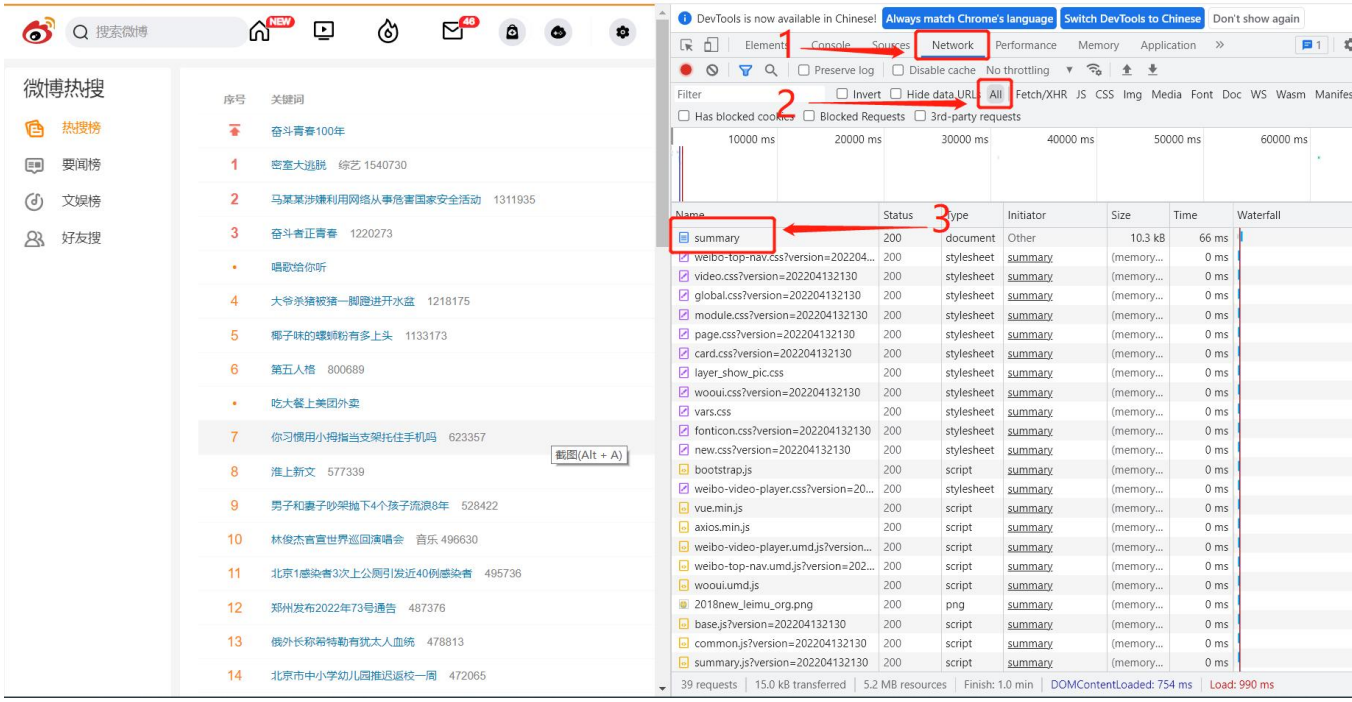

⑤、点击 summary 后出现右侧窗口，点击 Header 能够得到相关报文字段，如下图所示：

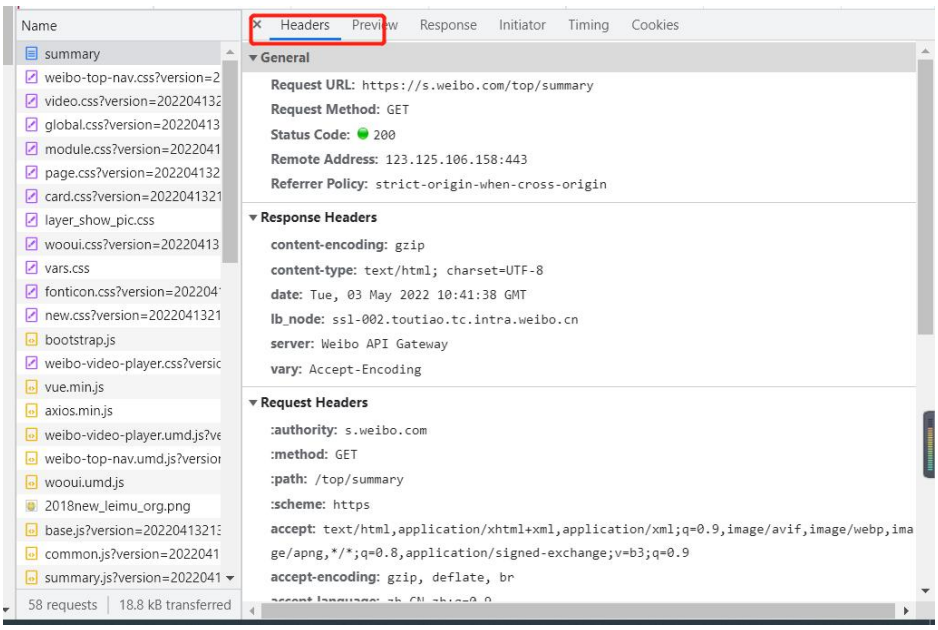

⑥、本实验所需的字段均在 Request Header 中，即下图中标注的字段。具体字段对应的值以各自浏览器为主，无需与图中字段值相同。

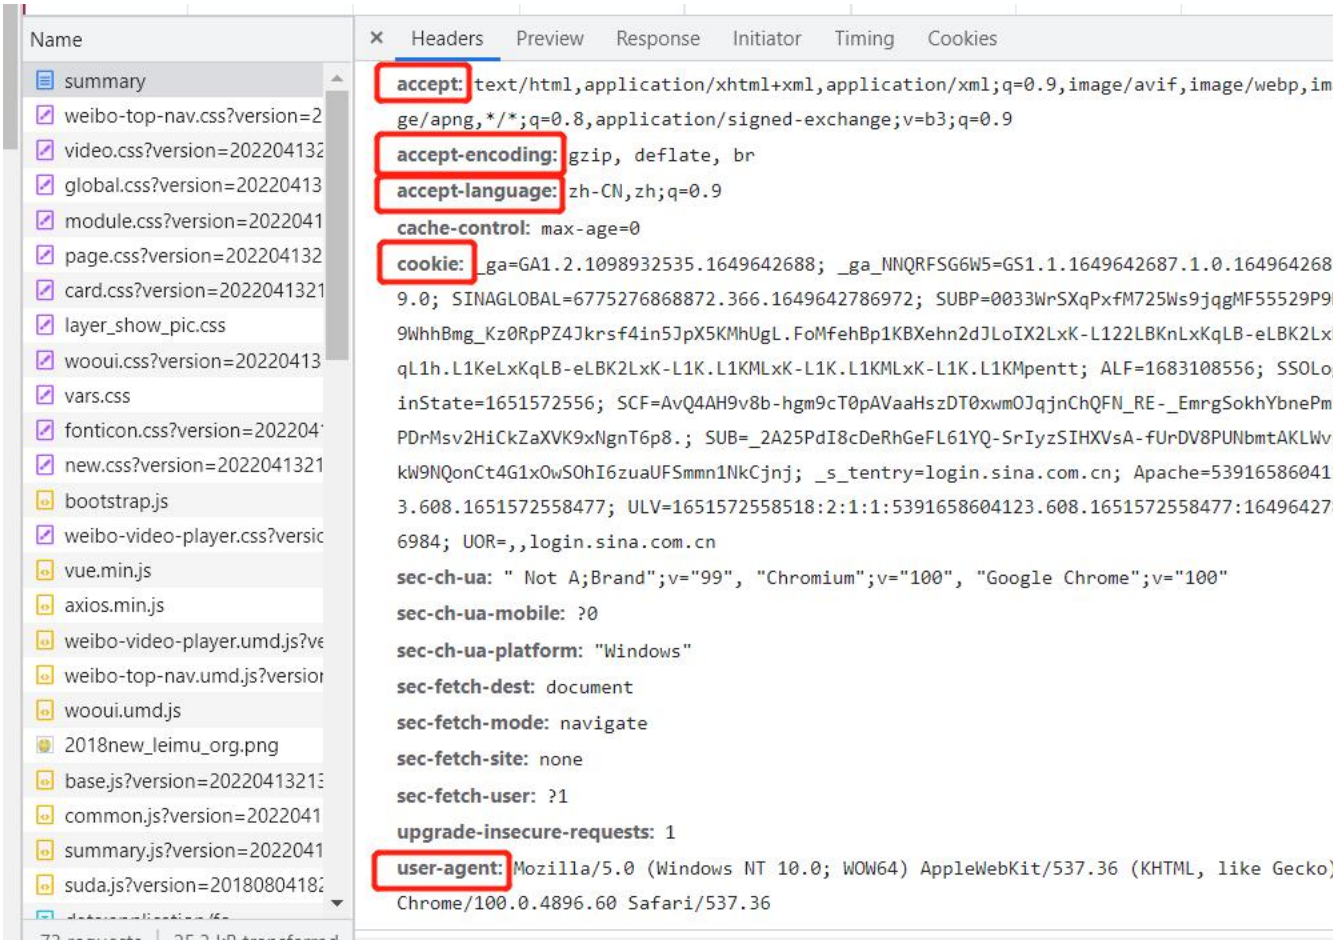

⑦、记住 User-Agent：Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/119.0.0.0 Safari/537.36 Edg/119.0.0.0

⑧、Accept：text/html,application/xhtml+xml,application/xml;q=0.9,image/webp,image/apng,*/*;q=0.8,application/signed-exchange;v=b3;q=0.7

⑨、Accept-Language：zh-CN,zh;q=0.9,en;q=0.8,en-GB;q=0.7,en-US;q=0.6

⑩、Accept-Ecoding：gzip, deflate, br

⑪、Cookie：SUB=_2AkMSZ6c6f8NxqwFRmfoVxGjlbI9-zg_EieKkO1bhJRMxHRl-yT9vqkcTtRB6OeeJ1kbwxbAqAOG-rwsO3fFJIo_wTR_5; SUBP=0033WrSXqPxfM72-Ws9jqgMF55529P9D9W5B6DhQN3sTeyP3h_bm8GI8; SINAGLOBAL=8919160298192.982.1700537447732; _s_tentry=link.zhihu.com; UOR=,,link.zhihu.com; Apache=300539231686.1499.1700551101473; ULV=1700551101482:2:2:2:300539231686.1499.1700551101473:1700537447741

⑫、五个字段值，后续在代码中会用到。

2、获取发送邮箱的 smtp 授权码

smtp 授权码只需要发送邮箱的，不是接收邮箱的。因为不是我们自己主动发送邮件，通过第三方（python 代码）发送的，所以需要获取 smtp 授权码进行第三方登录。本实验以 QQ 邮箱为例，获取 QQ 邮箱的 smtp 授权码，其他类型邮箱类似或者可以上网查找相关资料。

①、打开 QQ 邮箱设置-账户，往下滑找到如图所示的选项。

②、将上图中的四个服务全开起来，具体操作步骤略，点击开启的时候会有相关提示 jucbejryqdfffiah

③、点击图中生成授权码，并根据提示进行操作。

④、操作过后会得到下面的提示框，记住显示的授权码，备用。

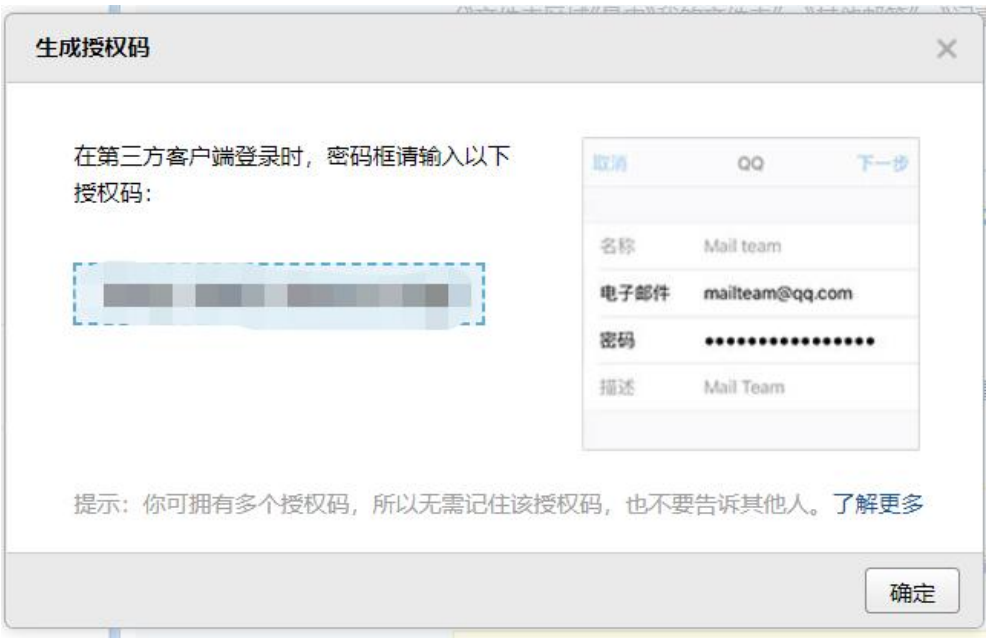

3、其他说明

浏览微博热搜榜 html 网页源码可发现整个热搜榜内容均在<tbody>…</tbody>，每条热搜的信息（序号、关键词、热度）均在<tr>…</tr>标签内。

本实验还是使用 CSS 选择器获取指定元素信息。具体某条热搜链接和关键词的 CSS 选择器为：

#pl_top_realtimehot > table > tbody > tr:nth-child(1) > td.td-02 > a

为获取全部热搜的 CSS 选择器，将上面的改为：

#pl_top_realtimehot > table > tbody > tr> td.td-02 > a

同理，获取全部热搜热度的 CSS 选择器为：

#pl_top_realtimehot > table > tbody > tr > td.td-02 > span

热搜榜置顶没有显示热度，需要特殊处理。另外就是部分热搜的链接会出现别的情况，也需要特殊处理。

4. 实验要求

（1）提交视频，不需提交实习报告，视频作为平时成绩的一部分。

（2）分别给出（一）显示影片基本信息、（二）存储影片详细信息和（三）访问热搜榜并发送邮件三个任务的源代码。

（3）三个任务的详细步骤分别做成三个小视频，视频要求边敲代码边配音讲解。将源代码和视频打包提交至 110 系统，命名格式为学号+姓名，。