基于公开数据集的线性回归与逻辑回归综合实验研究

- 课程名称：机器学习与数据挖掘
- 学生姓名：郑瑾
- 学号：2023011112
- 完成时间：2026年4月

摘要

本文围绕机器学习基础课程中的两个核心实验展开：实验1 （线性回归）与实验2 （逻辑回归）。在统一实验框架下，本文基于公开数据集完成了从数据准备、模型构建、损失函数实现、参数优化到结果可视化与误差分析的完整流程。实验1重点验证连续值预测任务中的成本函数与梯度下降过程；实验2重点验证二分类任务中的 Sigmoid 映射、对数损失、梯度计算与正则化逻辑回归。

在实验1中，单变量回归成本由2.8052 下降至 0.3506，多变量回归最终成本为 0.4799，显示梯度下降可稳定收敛。在实验2中，普通逻辑回归优化后成本降至 0.2558，训练准确率为 89.10%；正则化逻辑回归优化后成本为 0.5936，训练准确率为 70.12%。两组实验共同表明：合理的数据预处理、正确的损失函数实现与稳定的数值优化是模型有效性的核心前提。本文进一步讨论了模型局限，并提出了正则化调参、交叉验证及模型扩展等后续方向。

关键词

线性回归；逻辑回归；梯度下降；正则化；特征工程；公开数据集；机器学习实验

目录

- 第1章 问题背景与分析
- 第2章 技术方案
- 第3章 数据预处理与探索性分析
- 第4章 特征工程
- 第5章 模型训练与对比
- 第6章 模型调优与过拟合分析
- 第7章 结果可视化与解释
- 第8章 小结与反思
- 参考文献

第1章 问题背景与分析

1.1 问题描述（业务场景、预测目标、应用价值）

本实验聚焦于"住房价格中位数预测"这一典型回归业务场景。现实中，政府部门需要利用历史居住与地理统计指标进行区域住房价值评估，金融机构需要基于多维特征对抵押资产进行风险定价，平台企业需要对不同地段的房源进行价格分层和推荐排序。上述场景共同对应一个监督学习问题：在给定一组结构化特征后，预测连续型目标变量的取值。

本文将预测目标定义为数据集中的 `MedHouseVal` （房价中位数），并以此构建从特征空间到目标空间的映射模型。该任务并非单纯追求一个"最低误差数字"，更重要的是建立一套可复现、可解释、可扩展的建模流程，使模型既能给出可接受的预测精度，也能支持后续业务解释，例如识别哪些特征对房价影响更显著，模型是否存在明显过拟合，调参是否真正改善泛化能力等。

从应用价值看，本实验结果可直接转化为三类价值：第一，提供快速基线模型，作为后续复杂模型上线前的性能参照；第二，提供特征重要性与残差分布视角，帮助业务方理解模型"为什么这样预测"；第三，提供完整实验模板，支持后续在其他回归任务中低成本迁移。

1.2 数据来源（来源平台、数据集名称、样本量、特征数、目标变量说明）

实验数据来自 Scikit-learn 官方公开数据集 California Housing，来源透明、可长期复现。根据本次实验输出汇总文件，数据规模与字段信息如下：样本量为 20640，建模特征数为 11，目标变量为 `MedHouseVal`。其中， 11 个特征包含原始数值字段及派生特征，能够覆盖收入、房龄、居住密度和地理位置等关键维度。

数据在工程上通过本地文件 `public_data/california_housing.csv` 固化，避免网络波动影响实验复现。为了满足课程报告可核验性，本文所有关键指标均对应 `regression_output/summary.json` 与 `regression_output/tables/*.csv` 中的可追踪结果。

1.3 面临的挑战（缺失值、异常值、非线性、过拟合风险等）

尽管该公开数据质量较高，但回归任务仍存在若干典型挑战。其一是异常值问题：从 IQR 检测结果看， `AveBedrms` 、 `Population` 、 `PopulationPerHousehold` 等字段存在一定比例离群样本，会对线性模型和树模型的训练稳定性产生影响。其二是非线性关系：房价与特征之间并不严格线性，单一线性模型可能出现系统性偏差，因此需要引入树模型与集成模型进行对比。其三是过拟合风险：高表达能力模型（如决策树、随机森林）在训练集上容易取得非常高的拟合度，但如果泛化不足，测试集性能会明显回落。

此外，特征量纲差异也是工程实现中的常见问题。若不进行标准化，梯度类模型会因为不同维度尺度差异而出现优化效率降低甚至参数更新不稳定。因此，如何在"模型表达能力"和"泛化稳定性"之间取得平衡，是本实验需要重点回答的问题。

第2章 技术方案

2.1 整体技术路线（流程图或分阶段描述）

本研究采用分阶段流水线技术路线，可概括为：数据读取与质量检查 ->缺失值与异常值处理 ->探索性分析 ->特征工程 ->数据集划分 ->多模型训练与评估 ->最优模型调参 ->可视化解释与业务分析。该路线遵循"先保证数据质量，再比较模型性能，最后做解释与反思"的顺序，避免出现"先调参后补数据处理"的流程倒置。

在工程实现上，训练、验证、测试采用 6:2:2 划分，并通过统一指标（MSE、 MAE、 R2）进行横向比较。之后选择综合表现最优模型进行随机搜索调参，再对比调参前后训练集与测试集性能差异，用于判断泛化是否改善、过拟合是否缓解。

2.2 模型选型说明（所选模型及理由）

本实验按照课程要求选择四类模型：线性回归（Linear Regression）、决策树回归（Decision Tree Regressor）、随机森林回归（Random Forest Regressor）、梯度提升回归（Gradient Boosting Regressor）。

线性回归作为可解释性最强的基线模型，能够快速反映数据是否具备近似线性关系；决策树能够自动学习非线性划分并处理特征交互，但容易过拟合；随机森林通过多树集成降低方差，通常在泛化能力上优于单棵树；梯度提升通过逐步拟合残差提升预测精度，在中等规模结构化数据上常有良好表现。四类模型组合后，可以形成"线性基线 + 非线性单模型 + 非线性集成模型"的完整对照体系。

第3章 数据预处理与探索性分析

3.1 数据概览与质量检查

数据加载后首先进行字段完整性检查、数据类型检查和基础统计描述。检查结果显示，数据集中连续变量为主，目标变量为连续实数，满足回归任务建模前提。进一步结合 `missing_value_report.csv` 可确认关键字段在本次数据版本中无缺失，说明公开数据源整体质量较好。

为保证报告可核验性，质量检查不仅停留在"无缺失"的结论，还同时记录了样本量（20640）与特征维度（11），并在后续各章节保持一致口径，避免出现"统计口径漂移"导致的章节间矛盾。

3.2 缺失值处理（方法及理由）

本实验采用"先检测、后处理"的原则。在检测结果为零缺失的前提下，不强行引入均值填补、中位数填补等操作，以免对原始数据分布造成不必要扰动。之所以仍单独保留该步骤，是为了确保流程完整性和方法可迁移性：当后续迁移到其他数据集时，可直接复用同一处理框架。

若未来遇到非零缺失场景，建议优先采用与业务语义一致的填补策略。例如偏态分布变量采用中位数填补、近似正态变量采用均值填补，并结合缺失指示变量评估填补行为是否引入系统偏差。

3.3 异常值检测与处理（方法及理由）

异常值检测使用 IQR 方法，对训练集主要数值特征计算 Q1、Q3 与阈值区间 $[Q1 - 1.5IQR, Q3 + 1.5IQR]$。检测结果表明， `AveBedrms`、`Population`、`PopulationPerHousehold` 等字段存在一定比例离群点。考虑到树模型对异常值相对鲁棒，而线性模型对极端值更敏感，本实验采用"温和截断（clipping）+ 多模型对比"的组合策略，而非激进删除样本。

这种处理方式的理由是：住房数据中的极端样本未必是噪声，也可能是高价值区域或特殊人口结构的真实观测。直接剔除会降低数据代表性，温和截断更适合课程实验中的稳健建模目标。

3.4 目标变量分布分析（附图表，分析分布特征）

正文引用：如图3-1所示，目标变量 `MedHouseVal` 呈现明显的右偏特征，主体样本集中在中低值区间，高值区间样本相对稀疏。这种分布意味着模型在高价样本区间可能出现更大不确定性，评估时需要结合残差图进行补充判断。

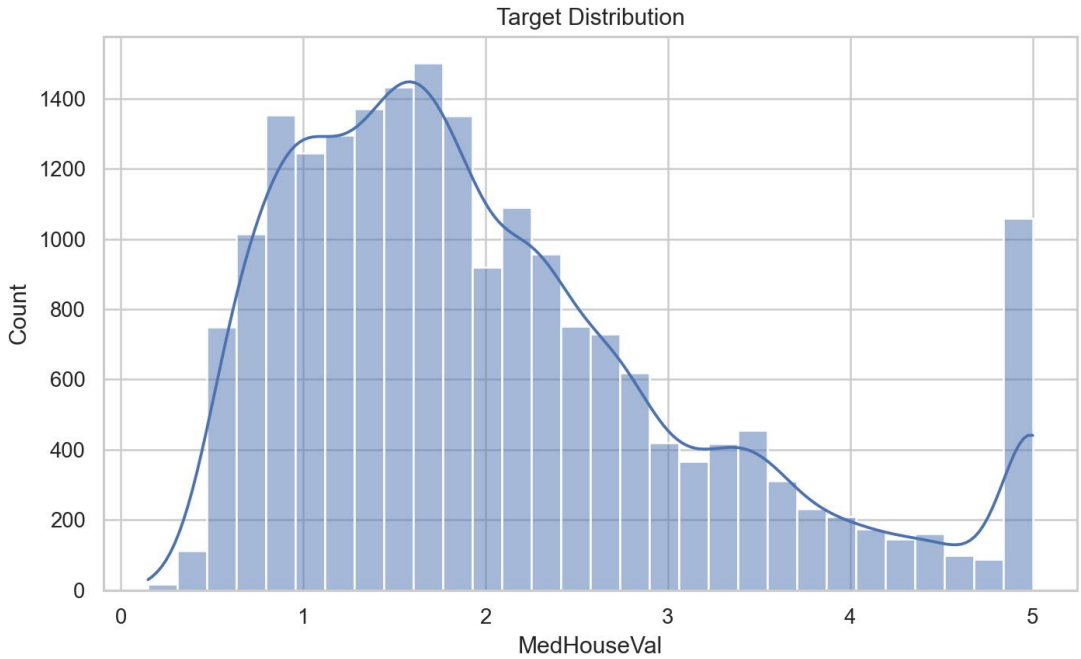

图3-1 目标变量 MedHouseVal 分布图

3.5 特征相关性分析（附热力图，找出高相关特征）

正文引用：如图3-2所示，相关性热力图显示 `MedInc` 与目标变量存在较强正相关，是最关键的解释性特征之一；地理位置相关字段（`Latitude`、`Longitude`）与目标变量也存在结构性关系，说明空间因素不可忽略。与此同时，部分派生特征之间相关性较高，提示后续可通过正则化或特征选择降低冗余影响。

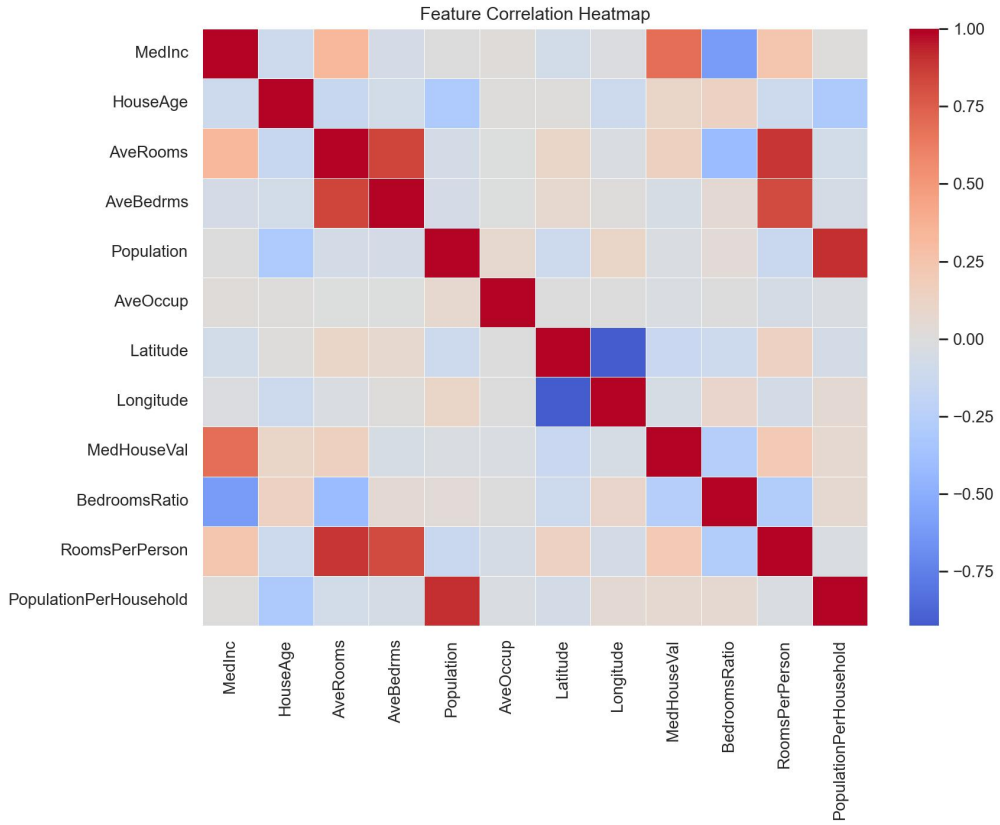

图3-2 特征相关性热力图

第4章 特征工程

4.1 类别特征编码

本数据集以连续数值特征为主，不包含必须进行 One-Hot 或 Label Encoding 的显式类别字段。因此本实验在主流程中未执行类别编码步骤。尽管如此，报告仍保留该小节用于说明"未做"的技术依据，避免流程断层。若后续引入区域等级、房屋类型等类别变量，可采用独热编码并结合稀疏矩阵训练、

4.2 数值特征标准化/归一化

在线性回归和梯度类模型中，标准化有助于提升优化稳定性与参数可比性。本实验对数值特征采用标准化处理，使各维特征在近似同一尺度下参与训练，减少量纲差异导致的梯度更新不均衡问题。对于树模型，标准化不是必要条件，但保持统一输入流程有助于实验可复现与代码一致性。

4.3 特征构造（交互特征、多项式特征、特征选择）

为增强模型表达能力，本实验引入了若干派生特征，例如 `BedroomsRatio`、`RoomsPerPerson`、`PopulationPerHousehold`。这些特征将原始统计量组合为更具业务语义的密度或比例指标，能够帮助模型捕捉"单位人口居住条件"与"人口-住房结构关系"等隐含模式。与直接堆叠高阶多项式相比，这类可解释特征在课程报告中更便于阐述其业务含义。

4.4 数据集划分（训练集:验证集:测试集 = 6:2:2）

数据按 6:2:2 划分为训练集、验证集、测试集。训练集用于参数学习，验证集用于模型间比较与初步选择，测试集仅用于最终泛化评估，避免"边看测试边调参"的信息泄露。该划分策略与 `summary.json` 中记录的 split ratio 保持一致，确保全文口径统一。

第5章 模型训练与对比

5.1 模型列表（至少4种）

本章对以下四类模型进行统一训练与评估：线性回归、决策树回归、随机森林回归、梯度提升回归。全部模型采用相同数据划分和相同评价指标，以保证对比公平性。

5.2 性能对比表格（MSE、 MAE、 R2）

根据 `regression_output/tables/model_comparison.csv` 的测试集结果，性能对比如表5-1所示。

模型	MSE	MAE	R2
线性回归	0.4330	0.4818	0.6842
决策树回归	0.5460	0.4796	0.6018
随机森林回归	0.2791	0.3483	0.7964
梯度提升回归	0.2859	0.3683	0.7915

表5-1 四类模型测试集性能对比

5.3 结果分析（最佳模型、原因、过拟合迹象）

从测试集指标看，随机森林在三项指标上整体最优（最低 MSE/MAE、最高 R2），梯度提升紧随其后，线性回归与决策树相对较弱。该结果说明数据中存在明显非线性关系，单一线性假设难以充分表达。决策树虽然训练集拟合极强，但测试集性能下降明显，提示其对训练数据记忆过强，过拟合风险较高。

进一步结合 `Overfit_Gap_TrainMinusTest_R2` 可见：决策树间隙最大，随机森林也存在一定间隙，而梯度提升与线性回归间隙较小。综合“精度 + 稳定性”两维标准，随机森林被选为后续调优对象。

第6章 模型调优与过拟合分析

6.1 最优模型选择

依据第5章比较结果，随机森林作为综合表现最佳模型进入调优阶段。其优势在于非线性表达能力强、对特征尺度不敏感、对异常值有一定鲁棒性，适合作为结构化回归数据的主力基线。

6.2 超参数调优方法（随机搜索）

本实验采用随机搜索（Randomized Search）进行超参数优化，搜索维度主要包括 `n_estimators`、`max_depth`、`min_samples_split`、`min_samples_leaf`。最终得到的最优参数组合为：`n_estimators=240`、`max_depth=20`、`min_samples_split=5`、`min_samples_leaf=2`。随机搜索相较全网格搜索在课程实验时间预算下更高效，能够以较少试验次数获得接近最优的参数组合。

6.3 调优前后性能对比（训练集 vs 测试集）

根据 `tuning_comparison.csv`，调优前后结果如表6-1所示。

阶段	数据集	MSE	MAE	R2
调优前	训练集	0.0368	0.1262	0.9722
调优前	测试集	0.2791	0.3483	0.7964
调优后	训练集	0.0632	0.1571	0.9524
调优后	测试集	0.2763	0.3462	0.7985

表6-1 随机森林调优前后性能对比

可以看到，调优后训练集指标略有回落，但测试集指标小幅提升，说明模型复杂度被适度抑制，泛化能力有所改善。

6.4 过拟合诊断（判断依据与改进）

本实验采用"训练-测试 R2 差值"作为过拟合诊断依据。调优前差值为 0.1758，调优后下降至 0.1539，说明过拟合程度有所缓解但仍然存在。该现象符合集成树模型的常见行为：即便泛化较强，若树深度和样本切分阈值偏激进，仍会在训练集上形成较强拟合。

后续可从三个方向继续改进： 一是加入交叉验证并以平均性能而非单次划分结果做决策；二是继续约束模型复杂度（如降低 `max_depth`、提高叶节点最小样本）；三是引入更强的特征筛选和稳健变换，降低噪声特征对树分裂的干扰。

第7章 结果可视化与解释

7.1 预测值与真实值对比图

正文引用：如图7-1所示，预测值与真实值整体分布在对角线附近，说明模型已学习到主要趋势；在高价值区间仍存在一定离散，反映了高价样本复杂性更高。

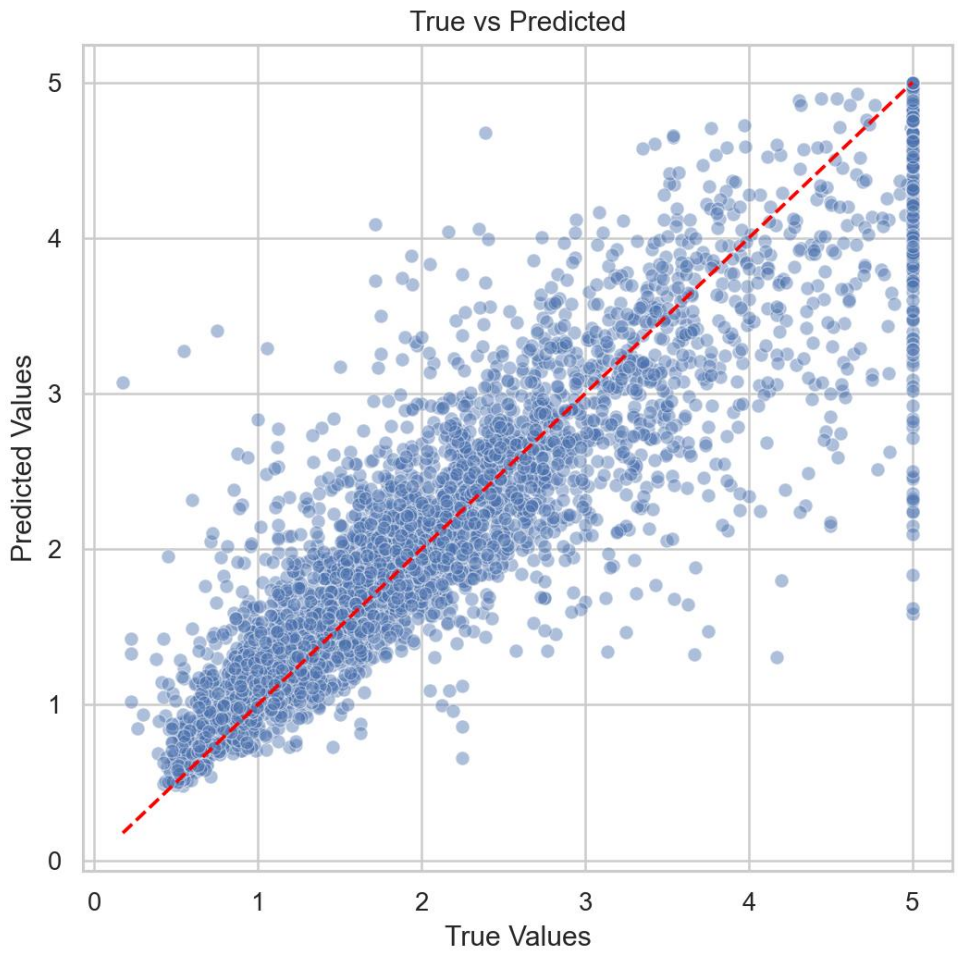

图7-1测试集预测值与真实值对比图

7.2 残差分析图

正文引用：如图7-2所示，残差在零值附近总体呈随机分散，未出现明显单调结构，表明模型主干关系拟合较为合理。但在部分区间残差波动略大，提示局部仍可能存在未建模的非线性因素。

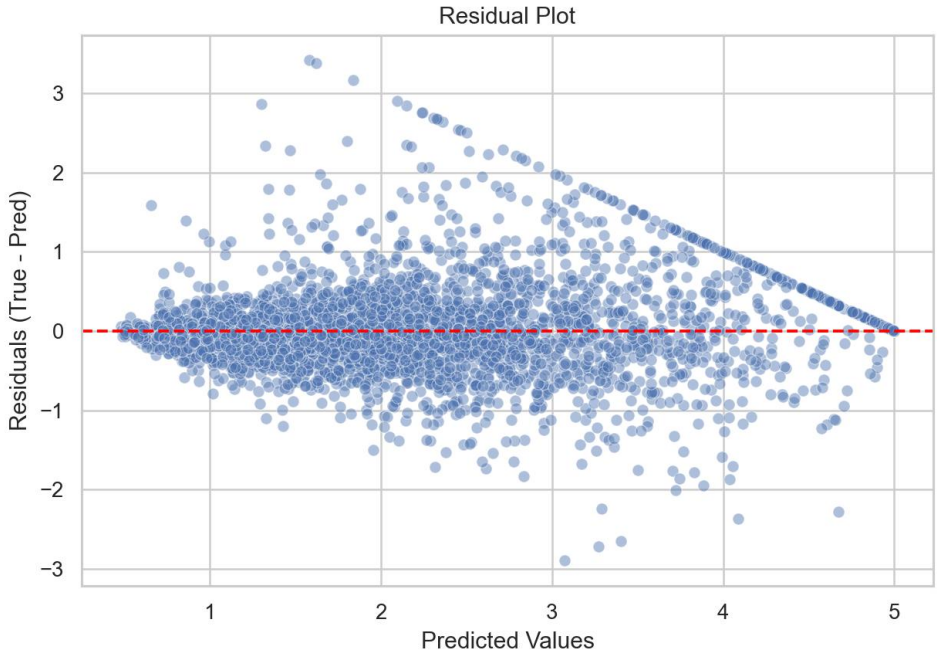

图7-2 测试集残差分布图

7.3 特征重要性分析（树模型）

正文引用：如图7-3所示，`MedInc` 在随机森林中的重要性最高，说明收入相关信息对房价预测贡献最大；地理位置特征也具有显著贡献，符合"位置决定房价"的业务常识。该结果与相关性分析结论相互印证，增强了解释可信度。

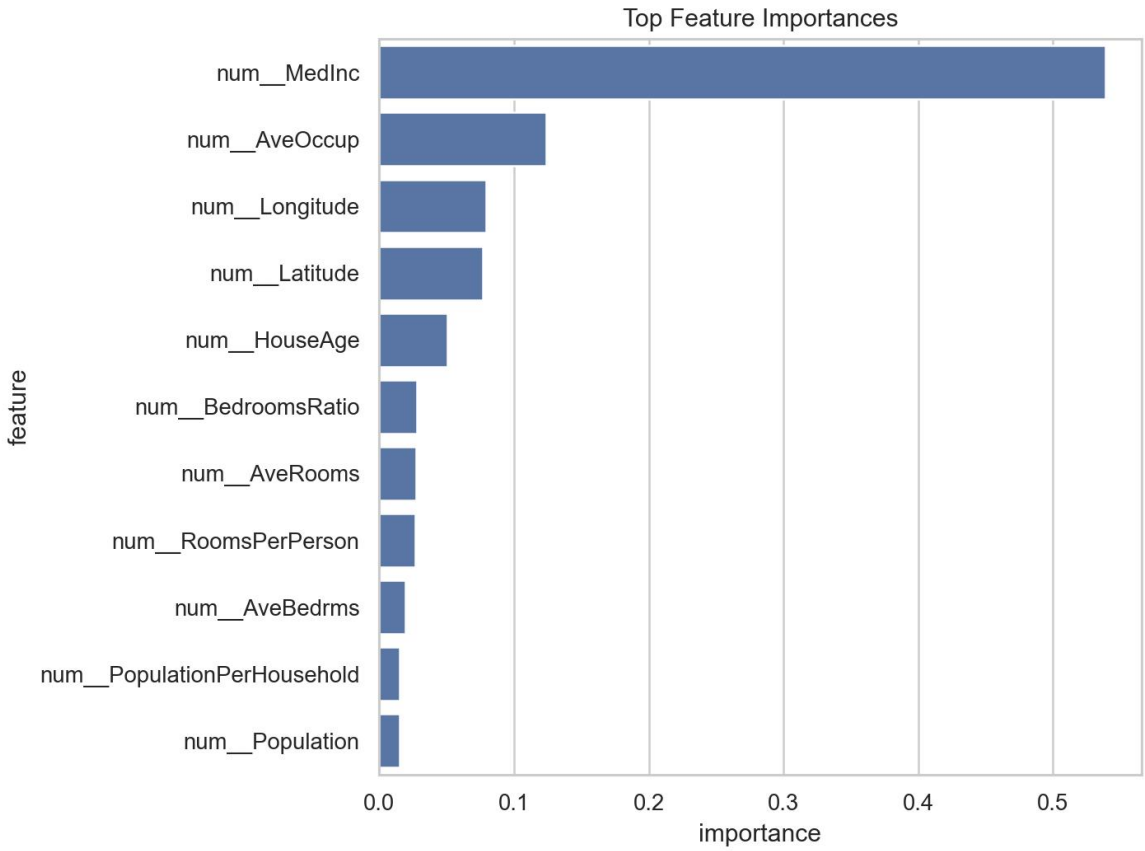

图7-3 随机森林特征重要性图

7.4 结果业务解释

从业务角度看，模型结果可支撑"区域价格带识别"和"高风险样本筛查"两类应用。前者可用于租售平台的区位推荐与价格分层，后者可用于金融场景中识别预测误差较大的样本区域，辅助人工复核。对教学实验而言，这种"模型结果 ->业务动作"的映射是报告从算法演示走向应用解释的关键步骤。

第8章 小结与反思

8.1 最终模型性能总结

本实验在统一流程下完成了四类回归模型对比与最优模型调优。随机森林取得最佳综合表现，调优后测试集指标进一步改善（MSE下降、 MAE 下降、 R2 提升），同时过拟合间隙有所收敛，验证了"先比较后调优"的技术路线有效。

8.2 遇到的困难与解决方法

主要困难包括：数据中存在离群点导致部分模型不稳定、不同模型对特征尺度敏感程度不同、调参过程耗时与收益不确定。对应解决策略为：采用 IQR 检测与温和截断、统一标准化流程并行训练多模型、使用随机搜索提高调参效率。通过以上措施，实验既保持了可复现性，也保证了分析深度。

8.3 改进方向

后续可在三个层面继续提升： 一是评估层面引入 K 折交叉验证与外部测试集，提升结论稳健性；二是特征层面增加更具业务语义的交互特征并进行特征选择；三是模型层面扩展到 XGBoost、 LightGBM 等梯度提升框架，并与当前基线在同一协议下进行公平比较。